K-MENAS CLUSTERING

```
In [1]:
          import numpy as np
          import pandas as pd
          import matplotlib.pyplot as plt
          import seaborn as sns
          from sklearn.cluster import KMeans
 In [2]:
          cus data=pd.read csv('E:/Mall Customers.csv')
 In [3]:
          cus data.head(3)
            CustomerID Gender Age Annual Income (k$) Spending Score (1-100)
Out[3]:
                         Male
                               19
                                                                   39
                    2
                                                15
                                                                   81
                               21
                         Male
          2
                                                                    6
                    3 Female
                               20
                                                16
 In [4]:
          cus_data.shape
         (200, 5)
Out[4]:
 In [5]:
          cus_data.isna().sum()
                                     0
         CustomerID
Out[5]:
                                     0
         Gender
                                     0
         Annual Income (k$)
                                     0
         Spending Score (1-100)
         dtype: int64
 In [6]:
          cus_data.info()
         <class 'pandas.core.frame.DataFrame'>
          RangeIndex: 200 entries, 0 to 199
         Data columns (total 5 columns):
                                        Non-Null Count Dtype
          #
              Column
          0
              CustomerID
                                        200 non-null
                                                         int64
                                        200 non-null
                                                         object
          1
              Gender
              Age
                                        200 non-null
                                                         int64
              Annual Income (k$)
                                        200 non-null
                                                         int64
              Spending Score (1-100)
                                        200 non-null
                                                         int64
         dtypes: int64(4), object(1)
         memory usage: 7.9+ KB
 In [7]:
          cus_data.drop(['CustomerID','Gender'],axis=1,inplace=True)
 In [8]:
          cus_data.head(3)
Out[8]:
            Age Annual Income (k$) Spending Score (1-100)
             19
                              15
                                                 39
             21
                                                 81
          2
             20
                              16
                                                  6
 In [9]:
          X=cus_data.drop('Age',axis=1)
In [10]:
          X.head(3)
```

Out[10]:		Annual Income (k\$)	Spending Score (1-100)
	0	15	39
	1	15	81
	2	16	6

Chossing Optimum Number of Clusters using WCSS

For each value of K, we are calculating WCSS (Within-Cluster Sum of Square). WCSS is the sum of squared distance between each point and the centroid in a cluster. When we plot the WCSS with the K value, the plot looks like an Elbow. As the number of clusters increases, the WCSS value will start to decrease.

```
In [16]: ## finding wcss value for different number of clusters

WCSS=[]
    for i in range(1,11):
        kmeans=KMeans(n_clusters=i,init='k-means++',random_state=0)
        kmeans.fit(X)


        WCSS.append(kmeans.inertia_)

C:\ProgramData\Anaconda3\lib\site-packages\sklearn\cluster\_kmeans.py:881: UserWarning: KMeans is known to have a memory leak on Windows with MKL, when there are less chunks than available threads. You can avoid it by setting the environment variable OMP_NUM_THREADS=1.
        warnings.warn(
```

Inertia measures how well a dataset was clustered by K-Means. It is calculated by measuring the distance between each data point and its centroid, squaring this distance, and summing these squares across one cluster

```
# plot an elbow graph

#The elbow curve
plt.figure(figsize=(12,6))
plt.plot(range(1,11),WCSS)
plt.plot(range(1,11),WCSS, linewidth=2, color="red", marker ="8")
plt.xlabel("K Value")
plt.xticks(np.arange(1,11,1))
plt.ylabel("WCSS")
plt.show()
```




1 2 3 4 5 6 7 8 9 10 K Value

We find that there are 2 cut-off(elbow points[3,5]),so we take 5 cuz after that there is no sharp drop in graph

```
In [29]:
           #adding the labels to a column named label
           cus_data["label"] = Y
In [30]:
           cus_data.head(3)
             Age Annual Income (k$) Spending Score (1-100) label
                                                            4
          0
              19
                                15
              21
                                15
                                                            3
          2
              20
                                16
                                                      6
                                                            4
```

```
In [19]:
                                       kmeans = KMeans(n_clusters=5, init='k-means++', random_state=0)
                                       #5 clusters-0,1,2,3,4
                                       # return a label for each data point based on their cluster
                                       Y = kmeans.fit_predict(X)
                                       print(Y)
                                     [4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 3\ 4\ 
                                        1 1 1 1
                                                                                       1 1 1
                                                                                                             1
                                                                                                                     1 1 1
                                                                                                                                            2 0 2 0 2 0 2 0 2 0 2 0 2 0 2 1
```



Concluison- The customers having very low income they purchase less and with more income they are careful while purchasing, so coustomers with medium income purchase more and spend more

```
In [ ]:
```